Actor-Crítico con Componente de Descubrimiento: Exploración Dirigida por Incertidumbre en Asteroids

Cristian Castro Tapiero
Cód. 20222578114
Universidad Distrital Francisco José de Caldas
Bogotá, Colombia
ccastrot@udistrital.edu.co

Daniel Esteban Pardo Moreno
Cód. 20222578072
Universidad Distrital Francisco José de Caldas
Bogotá, Colombia
depardom@udistrital.edu.co

***Resumen*—En los métodos actor-crítico el actor depende de un crítico que también está aprendiendo, por lo que un crítico equivocado puede orientar mal la política; además, la exploración suele ser no dirigida. Este trabajo propone el *Discovery Actor-Critic* (DAC), una extensión de A2C con dos componentes: (i) un ensamble de K críticos cuyo desacuerdo $\sigma_V(s)$ cuantifica la confianza en la evaluación y pondera el gradiente del actor, y (ii) un módulo de descubrimiento formado por M modelos de dinámica sobre un codificador aleatorio fijo, cuyo desacuerdo mide la novedad epistémica de cada acción. Cuando $\sigma_V(s)$ supera su media móvil, el agente "se detiene a preguntar": consulta el mapa de novedad de todas las acciones e inclina su política hacia las de consecuencias desconocidas, corrigiendo el sesgo resultante con pesos de importancia truncados. El agente se entrenó en `ALE/Asteroids-v5` y se comparó con un A2C estándar con el mismo código y presupuesto. En un experimento preliminar (una semilla; 3×10^5 pasos para DAC y 10^5 para A2C), DAC duplicó el puntaje del agente aleatorio en evaluación (1286 frente a 612), pero no superó a A2C con igual presupuesto (1046 frente a 1190 puntos promedio en entrenamiento a 10^5 pasos). Se analizan las causas y los ajustes que requiere el método.**

***Palabras clave*—aprendizaje por refuerzo, actor-crítico, exploración, curiosidad, ensambles, Atari, Asteroids.**

I. Introducción

Los métodos actor-crítico combinan una política parametrizada (actor) con una función de valor (crítico) que reduce la varianza del gradiente de política [1], [2]. Esta dependencia tiene dos debilidades. Primero, el crítico se aprende en paralelo con el actor; en estados poco visitados su estimación es poco fiable y puede "engañar" al actor, un fenómeno documentado en métodos actor-crítico con aproximación de funciones [3]. Segundo, la exploración depende del muestreo estocástico de la política o de un término de entropía, por lo que el agente nunca evalúa de forma explícita si existe otra acción cuyas consecuencias aún no conoce.

Este trabajo aborda ambos problemas con un mismo principio: *medir la incertidumbre con desacuerdo entre redes*. El desacuerdo entre críticos indica cuándo el agente no sabe evaluar un estado; el desacuerdo entre modelos de dinámica indica qué acción le enseñaría algo nuevo. La combinación produce un mecanismo explícito de consulta: el agente pregunta por acciones alternativas solo donde su evaluación es incierta.

Las contribuciones son: (1) una formulación matemática que extiende A2C con un ensamble de críticos, un módulo de descubrimiento y una política de comportamiento con corrección *off-policy*; (2) una implementación en PyTorch sobre Gymnasium/ALE; y (3) una evaluación experimental frente a A2C y a un agente aleatorio en Asteroids.

II. Trabajos relacionados

A2C/A3C [2] es la base del método, con ventajas calculadas mediante GAE [4] y el codificador convolucional de DQN [5]. La exploración por curiosidad usa como recompensa intrínseca el error de un modelo predictivo, como en ICM [6] y RND [7]; el error de predicción, sin embargo, también es alto en transiciones estocásticas. Pathak *et al.* [8] proponen en su lugar el desacuerdo de un ensamble de modelos, que decrece con los datos aunque el entorno sea aleatorio. Los ensambles con máscaras *bootstrap* se han usado para estimar incertidumbre en el valor [9]. La corrección por importancia truncada proviene de V-trace/IMPALA [10]. DAC combina estas ideas en un mecanismo de decisión: la incertidumbre del crítico decide *cuándo* explorar y la incertidumbre del modelo de dinámica decide *qué* explorar.

III. Formulación matemática

A. Actor-crítico base

Se considera un MDP $(\mathcal{S}, \mathcal{A}, P, r, \gamma)$ con $|\mathcal{A}| = 14$. Un codificador compartido $h = \phi_\omega(s) \in \mathbb{R}^{512}$ alimenta al actor $\pi_\theta(a \mid s)$ y al crítico $V(s)$. A2C minimiza

$$\mathcal{L}_{\text{A2C}} = -\mathbb{E}\big[\hat{A}_t \log \pi_\theta(a_t \mid s_t)\big] - \beta\, \mathbb{E}\big[\mathcal{H}(\pi_\theta(\cdot \mid s_t))\big] + c_V\, \mathbb{E}\big[(V(s_t) - R_t)^2\big], \quad (1)$$

donde la ventaja se estima con GAE(λ) [4]:

$$\delta_t = r_t + \gamma V(s_{t+1})(1 - d_t) - V(s_t), \quad (2)$$

$$\hat{A}_t = \delta_t + \gamma\lambda(1 - d_t)\hat{A}_{t+1}, \qquad R_t = \hat{A}_t + V(s_t). \quad (3)$$

B. Ensamble de críticos y confianza

Se reemplaza V por K cabezas $V_k^E(s)$, $k = 1, \dots, K$, sobre el mismo h:

$$\bar{V}^E(s) = \frac{1}{K} \sum_{k=1}^{K} V_k^E(s), \tag{4}$$

$$\sigma_V(s) = \sqrt{\frac{1}{K-1} \sum_{k=1}^{K} \big(V_k^E(s) - \bar{V}^E(s)\big)^2}. \tag{5}$$

$\bar{V}^E$ se usa en GAE y σ_V mide cuánto se puede confiar en la evaluación. El gradiente del actor se pondera con

$$w(s) = \frac{1}{1 + \kappa\, \sigma_V(s)/\bar{\sigma}_{\mathcal{B}}}, \tag{6}$$

con $\bar{\sigma}_{\mathcal{B}}$ la media de σ_V en el lote: donde los críticos discrepan, el actor da pasos más pequeños.

C. Módulo de descubrimiento

Sea $\psi : \mathcal{S} \to \mathbb{R}^d$ ($d = 256$) una red convolucional de pesos aleatorios *fijos* y $\tilde{\psi}(s) = \sqrt{d}\, \psi(s)/\|\psi(s)\|$. Un ensamble de M modelos de dinámica $g_m(\tilde{\psi}(s), e_a) \approx \tilde{\psi}(s')$, con e_a la codificación *one-hot* de la acción, define el desacuerdo

$$D(s, a) = \frac{1}{d} \sum_{j=1}^{d} \mathrm{Var}_m \big[g_m(\tilde{\psi}(s), e_a)\big]_j. \tag{7}$$

D es alto solo en transiciones poco vistas, por lo que mide ignorancia del agente y no ruido del entorno [8]. La recompensa intrínseca es $r_t^I = D(s_t, a_t)/\sigma_{R^I}$, donde σ_{R^I} es la desviación móvil del retorno intrínseco descontado, como en [7].

D. Regla de consulta y política de comportamiento

El agente "pregunta" en el estado s_t si

$$q_t = \mathbf{1}\big[\sigma_V(s_t) > \bar{\sigma}_t\big] \;\vee\; \mathbf{1}\big[u_t < \epsilon\big], \quad u_t \sim \mathcal{U}(0, 1), \tag{8}$$

con $\bar{\sigma}_t \leftarrow 0.99\, \bar{\sigma}_{t-1} + 0.01\, \sigma_V$ una media móvil exponencial. Al preguntar, evalúa el mapa de novedad para *todas* las acciones, $\hat{U}(s, \cdot)$ (el desacuerdo $D(s, \cdot)$ estandarizado sobre $\mathcal{A}$), y actúa con

$$\mu(a \mid s) = \frac{\pi_\theta(a \mid s) \exp\big(\eta_t\, \hat{U}(s, a)\big)}{\sum_{a'} \pi_\theta(a' \mid s) \exp\big(\eta_t\, \hat{U}(s, a')\big)}, \tag{9}$$

donde η_t decrece linealmente de η_0 a η_f. La política de comportamiento es $b = \mu$ si $q_t = 1$ y $b = \pi_\theta$ en otro caso.

E. Objetivo completo

Con ventajas extrínseca (episódica) e intrínseca (no episódica, $d_t \equiv 0$), $\hat{A}_t = A_t^E + c_I A_t^I$ normalizada en el lote, y el peso de importancia truncado [10] $\bar{\rho}_t = \min\big(1, \pi_\theta(a_t \mid s_t)/b(a_t \mid s_t)\big)$, la pérdida de la red principal es

$$\mathcal{L} = \mathcal{L}_\pi + c_V \big(\mathcal{L}_{V^E} + \mathcal{L}_{V^I}\big), \tag{10}$$

$$\mathcal{L}_\pi = -\mathbb{E}\big[\bar{\rho}_t\, w(s_t)\, \hat{A}_t \log \pi_\theta(a_t \mid s_t)\big] - \beta\, \mathbb{E}\big[\mathcal{H}(\pi_\theta)\big], \tag{11}$$

$$\mathcal{L}_{V^E} = \frac{\sum_{k,t} m_{k,t} \big(V_k^E(s_t) - R_t^E\big)^2}{\sum_{k,t} m_{k,t}}, \tag{12}$$

$$\mathcal{L}_{V^I} = \mathbb{E}\big[(V^I(s_t) - R_t^I)^2\big], \tag{13}$$

Algoritmo 1 Discovery Actor-Critic (una iteración)

for $t = 1, \dots, T$ **en** N entornos **do**
  $\pi_\theta(\cdot \mid s_t),\ \{V_k^E(s_t)\} \leftarrow \mathrm{red}(s_t)$; calcular $\sigma_V(s_t)$
  actualizar $\bar{\sigma}$; $q_t \leftarrow [\sigma_V > \bar{\sigma}] \vee [u < \epsilon]$
  if q_t **then** ▷ el agente pregunta
    $\hat{U}(s_t, \cdot) \leftarrow$ desacuerdo estandarizado sobre $\mathcal{A}$
    $b \leftarrow \mu \propto \pi_\theta \exp(\eta_t \hat{U})$
  else
    $b \leftarrow \pi_\theta$
  $a_t \sim b$; guardar $\log b(a_t \mid s_t)$; ejecutar a_t
  guardar $(s_t, a_t, \mathrm{sign}(r_t), s_{t+1}, d_t)$
$r_t^I \leftarrow D(s_t, a_t)/\sigma_{R^I}$ para todo el lote
$A^E, R^E \leftarrow$ GAE con $\bar{V}^E$; $A^I, R^I \leftarrow$ GAE no episódico con V^I
$\hat{A} \leftarrow \mathrm{norm}(A^E + c_I A^I)$; $\bar{\rho} \leftarrow \min(1, \pi_\theta/b)$; $w \leftarrow 1/(1 + \kappa\tilde{\sigma}_V)$
paso de Adam sobre $\mathcal{L}$ (ec. 10) con recorte de gradiente
paso de Adam sobre $\mathcal{L}_D$ con máscaras *bootstrap*
η_t y la tasa de aprendizaje decrecen linealmente

con máscaras $m_{k,t} \sim \mathrm{Bernoulli}(p)$ que mantienen diversos a los críticos [9]. Los modelos de dinámica minimizan, con un optimizador separado,

$$\mathcal{L}_D = \frac{\sum_{m,t} m'_{m,t}(1 - d_t)\, \frac{1}{d} \|g_m(\tilde{\psi}(s_t), e_{a_t}) - \tilde{\psi}(s_{t+1})\|^2}{\sum_{m,t} m'_{m,t}(1 - d_t)}. \tag{14}$$

Con $K = 1$, $\kappa = 0$ y sin módulo de descubrimiento, $\mathcal{L}$ se reduce exactamente a A2C, que es la línea base.

IV. Arquitectura del sistema

La Fig. 1 resume los componentes y el flujo de información.

Red actor-crítico. El codificador es la CNN de [5] (convoluciones $32{\times}8{\times}8/4$, $64{\times}4{\times}4/2$, $64{\times}3{\times}3/1$ y capa densa de 512). Sobre él se ubican cinco cabezas lineales: actor (14 *logits*), $K = 3$ críticos extrínsecos y un crítico intrínseco. Las cabezas se inicializan ortogonalmente por separado (ganancia 0,01 para el actor y 1 para los críticos).

Módulo de descubrimiento. ψ replica la CNN con activación LeakyReLU y salida de 256, con gradiente desactivado. Cada g_m es un perceptrón $[256{+}14] \to 256 \to 256 \to 256$ con ReLU. $\hat{U}(s, \cdot)$ se obtiene evaluando las 14 acciones en un solo pase por lotes.

V. Procedimiento de entrenamiento

El Algoritmo 1 resume una iteración. Se recolectan $T = 16$ pasos en $N = 16$ entornos paralelos (256 transiciones por actualización), se calcula la recompensa intrínseca, se estiman las ventajas y se actualizan, en orden, la red principal y los modelos de dinámica.

Entorno. Se usa `ALE/Asteroids-v5` de Gymnasium [11], [13] con el protocolo de [12]: acciones pegajosas con probabilidad 0,25, salto de 4 cuadros, hasta 30 acciones nulas iniciales, escala de grises a $84{\times}84$ y apilamiento de

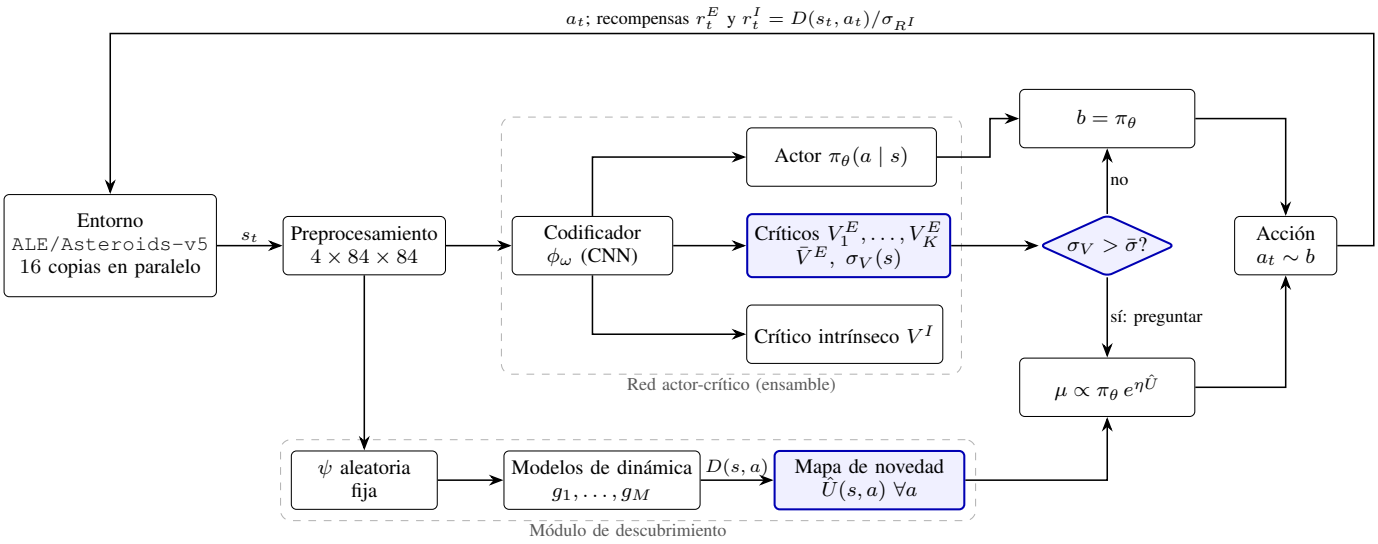


Fig. 1. Arquitectura de DAC. El desacuerdo entre críticos (σ_V) decide *cuándo* consultar; el mapa de novedad del módulo de descubrimiento decide *qué* acción explorar. Los componentes resaltados son la extensión propuesta sobre A2C.

Tabla I
HIPERPARÁMETROS

Símbolo	Descripción	Valor
N, T	entornos paralelos, pasos por iteración	16, 16
α	tasa de aprendizaje (Adam, lineal a 0)	$2{,}5 \times 10^{-4}$
γ, γ_I, λ	descuentos y parámetro de GAE	0,99, 0,99, 0,95
β, c_V	coeficientes de entropía y de valor	0,01, 0,5
—	recorte de la norma del gradiente	0,5
K, p	críticos y prob. de la máscara	3, 0,8
κ	sensibilidad del peso de confianza	1,0
M, d	modelos de dinámica y dim. de ψ	5, 256
c_I	peso de la ventaja intrínseca	0,5
—	tasa de aprendizaje de g_m	10^{-4}
$\eta_0 \to \eta_f$	inclinación hacia la novedad	$1{,}0 \to 0{,}1$
ϵ	probabilidad mínima de consulta	0,05

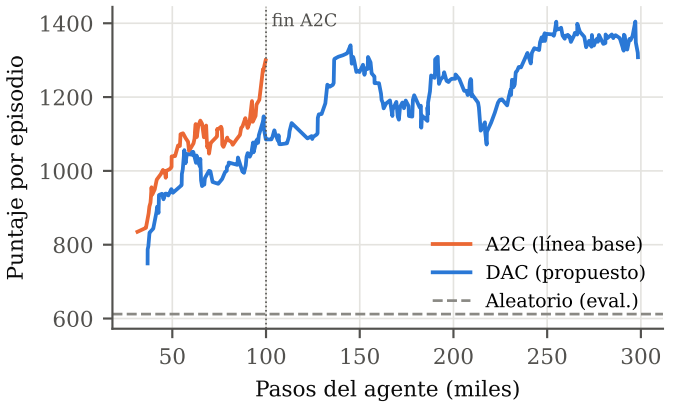


Fig. 2. Puntaje por episodio durante el entrenamiento (media móvil de 30 episodios). A2C se entrenó hasta 10^5 pasos (línea punteada) y DAC hasta 3×10^5.

4 cuadros. Las recompensas se recortan a su signo durante el entrenamiento; la evaluación reporta el puntaje real del juego.

Hiperparámetros. La Tabla I lista los valores usados. La línea base A2C usa el mismo código con $K = 1$, $\kappa = 0$ y sin módulo de descubrimiento, de modo que cualquier diferencia se atribuye a la extensión.

Modelo guardado. Al terminar, los pesos y la configuración se guardan en `checkpoints/dac.pt` y `checkpoints/a2c_baseline.pt`; la función `load_agent` los reconstruye para evaluarlos o para jugar.

VI. Experimentación y resultados

A. Protocolo

Por limitaciones de cómputo (CPU de 2 núcleos, sin GPU) se realizó un experimento preliminar con una sola semilla (seed $= 1$). DAC se entrenó durante 3×10^5 pasos del agente ($1{,}2 \times 10^6$ cuadros; 21 min a 238 pasos/s) y A2C durante 10^5 pasos (4 min a 423 pasos/s). Para comparar con el mismo presupuesto se usa la curva de entrenamiento de DAC en el paso 10^5. La evaluación final juega 5 episodios completos por agente con semillas no vistas en entrenamiento (desde 10 000), con la política estocástica y con la voraz ($\arg\max_a \pi_\theta$), y reporta el puntaje real del juego. Un agente que elige acciones al azar sirve como referencia inferior.

B. Rendimiento

La Fig. 2 muestra la media móvil (30 episodios) del puntaje durante el entrenamiento y la Tabla II resume los resultados.

Ambos agentes aprenden: DAC pasa de unos 750 puntos al inicio a 1340 y en evaluación alcanza 2,1 veces el puntaje aleatorio. Sin embargo, con el mismo presupuesto de 10^5 pasos A2C obtiene un puntaje de entrenamiento mayor (1190 frente a 1046), y en evaluación su media también es mayor, aunque con una varianza muy alta (± 637 en 5 episodios). Con una semilla y 5 episodios estas diferencias no son estadísticamente concluyentes, pero no hay evidencia de que DAC mejore la eficiencia de muestreo en este régimen.

Tabla II
RESULTADOS DEL EXPERIMENTO PRELIMINAR (UNA SEMILLA)

Agente	Pasos	Media ± desv.	[mín, máx]
Entrenamiento: últimos 50 episodios			
A2C	10^5	1190	—
DAC	10^5	1046	—
DAC	3×10^5	1340	—
Evaluación: 5 episodios no vistos			
Aleatorio	—	612 ± 105	[510, 780]
A2C, estocástica	10^5	1760 ± 637	[1280, 2950]
DAC, estocástica	3×10^5	1286 ± 318	[680, 1620]
A2C y DAC, voraz	—	140 ± 0	[140, 140]

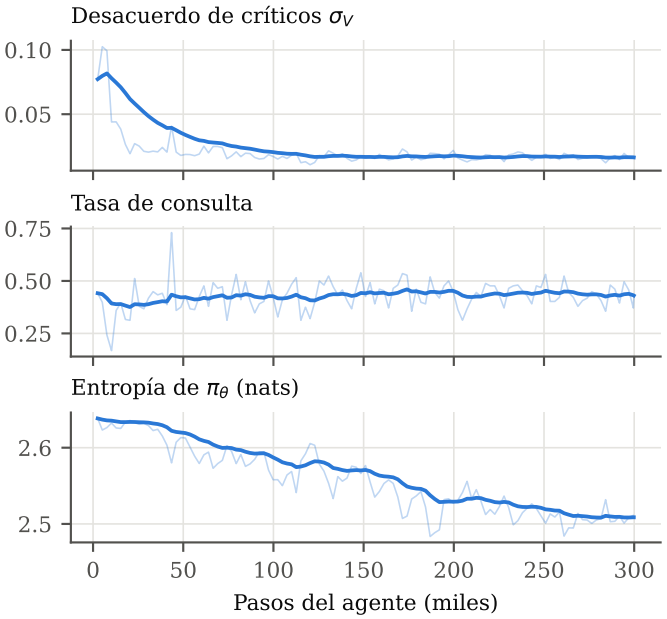


Fig. 3. Señales internas de DAC durante el entrenamiento: desacuerdo de los críticos, fracción de pasos en que el agente consulta el módulo de descubrimiento y entropía de la política (línea gruesa: media móvil exponencial).

Las políticas voraces de ambos agentes obtienen exactamente 140 puntos: al elegir siempre la acción más probable caen en un comportamiento repetitivo. En Atari se reporta normalmente la política estocástica, y este resultado confirma que la aleatoriedad residual de π_θ es necesaria.

C. Diagnóstico del componente de descubrimiento

La Fig. 3 muestra las señales internas de DAC.

- **Los críticos convergen.** σ_V baja de 0,050 a 0,016: a medida que el agente conoce el juego, sus críticos coinciden, que es el comportamiento esperado de una medida de incertidumbre.
- **La tasa de consulta no baja.** Se mantiene en torno a 0,43 durante todo el entrenamiento. Como el umbral $\bar{\sigma}$ es la media móvil del propio σ_V, la regla dispara en aproximadamente la mitad de los estados aunque la incertidumbre absoluta haya caído. El agente explora con μ en casi la mitad de sus acciones incluso al final.
- **La curiosidad se agota rápido.** La pérdida de los modelos de dinámica cae de 0,62 a 0,015 y la recompensa intrínseca normalizada de 0,049 a 4×10^{-4}. Pasados los primeros miles de pasos, la ventaja intrínseca aporta poco y el efecto de DAC proviene casi solo de la inclinación de la acción al consultar.
- **La corrección *off-policy* es moderada.** El peso medio $\bar{\rho}$ es 0,91, por lo que μ y π_θ no se alejan tanto como para anular el gradiente.
- **Costo.** DAC corre a 238 pasos/s frente a 423 de A2C (0,56 veces) por los M modelos y la evaluación de las 14 acciones.

D. Discusión

Los diagnósticos explican el resultado: el mecanismo de consulta está calibrado de forma relativa, así que nunca deja de explorar, y en Asteroids, con recompensa densa, esa exploración adicional compite con la explotación sin que la curiosidad aporte información útil por mucho tiempo. Esto sugiere cuatro ajustes: (i) un umbral absoluto o un percentil alto (p. ej. 90) para $\bar{\sigma}$, de modo que la tasa de consulta decrezca con la incertidumbre; (ii) un η_0 menor o un decaimiento más rápido; (iii) un mayor c_I o una normalización de r^I que no colapse; y (iv) entrenamientos de 10^7 cuadros o más con 3 a 5 semillas, que es la escala habitual en Atari [12]. Las ablaciones (solo ensamble, solo descubrimiento) permitirían atribuir el efecto de cada componente.

VII. JUSTIFICACIÓN DEL ENFOQUE E INNOVACIÓN

El enunciado identifica dos fallas del actor-crítico: el crítico puede engañar al actor y el agente nunca se detiene a considerar otra acción. DAC responde a cada una con un componente concreto:

- **Crítico que engaña.** En lugar de un único valor puntual, el ensamble ofrece una estimación con incertidumbre. El peso $w(s)$ reduce la influencia del crítico justo donde no es fiable, sin detener el aprendizaje en el resto de estados.
- **Descubrimiento de acciones.** El mapa $\hat{U}(s, \cdot)$ evalúa contrafácticamente las 14 acciones antes de actuar. Es, literalmente, la pregunta "¿qué otra acción me enseñaría algo?", respondida por un conjunto de redes neuronales adicional.
- **Cuándo preguntar.** Explorar en todos los estados desperdicia experiencia. La regla q_t vincula la consulta con la incertidumbre del crítico, y ϵ garantiza un mínimo de consultas aunque los críticos coincidan.
- **Corrección del sesgo.** Como el agente a veces actúa con $\mu \neq \pi_\theta$, el peso $\bar{\rho}_t$ mantiene el gradiente de política aproximadamente insesgado sin varianza explosiva.

Frente a la curiosidad clásica [6], [7], que solo agrega una recompensa intrínseca, DAC usa la novedad de dos maneras: como recompensa (aprendizaje a largo plazo) y como sesgo inmediato en la selección de la acción, restringido a los estados inciertos. Frente a epsilon-greedy, la exploración es dirigida en vez de uniforme.

VIII. Conclusiones

Se propuso DAC, una extensión de actor-crítico que agrega un ensamble de críticos y un módulo de descubrimiento basado en desacuerdo, junto con una regla explícita para decidir cuándo el agente pregunta por acciones alternativas y una corrección *off-policy* para el sesgo que esto introduce. La formulación se reduce a A2C cuando se desactivan los componentes nuevos, lo que permite una comparación controlada.

En un experimento preliminar en Asteroids, DAC aprendió a jugar (2,1 veces el puntaje aleatorio), y sus señales internas se comportan como se esperaba: los críticos convergen y la novedad se agota a medida que el agente conoce el entorno. No obstante, con el mismo presupuesto no superó a A2C. El análisis señala que la regla de consulta, al usar un umbral relativo, mantiene una exploración de alrededor del 43 % de las acciones durante todo el entrenamiento. Como trabajo futuro se proponen un umbral absoluto o por percentiles, entrenamientos más largos con varias semillas y estudios de ablación.

Disponibilidad del código

El cuaderno `Taller2_DAC_Asteroids.ipynb` contiene la implementación completa, el entrenamiento de ambos agentes, las gráficas, la evaluación y la descarga de los modelos guardados. Se ejecuta en Google Colab.

Referencias

[1] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. Cambridge, MA, USA: MIT Press, 2018.

[2] V. Mnih *et al.*, "Asynchronous methods for deep reinforcement learning," in *Proc. 33rd Int. Conf. Mach. Learn. (ICML)*, 2016, pp. 1928–1937.

[3] S. Fujimoto, H. van Hoof, and D. Meger, "Addressing function approximation error in actor-critic methods," in *Proc. 35th Int. Conf. Mach. Learn. (ICML)*, 2018, pp. 1587–1596.

[4] J. Schulman, P. Moritz, S. Levine, M. Jordan, and P. Abbeel, "High-dimensional continuous control using generalized advantage estimation," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2016.

[5] V. Mnih *et al.*, "Human-level control through deep reinforcement learning," *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.

[6] D. Pathak, P. Agrawal, A. A. Efros, and T. Darrell, "Curiosity-driven exploration by self-supervised prediction," in *Proc. 34th Int. Conf. Mach. Learn. (ICML)*, 2017, pp. 2778–2787.

[7] Y. Burda, H. Edwards, A. Storkey, and O. Klimov, "Exploration by random network distillation," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2019.

[8] D. Pathak, D. Gandhi, and A. Gupta, "Self-supervised exploration via disagreement," in *Proc. 36th Int. Conf. Mach. Learn. (ICML)*, 2019, pp. 5062–5071.

[9] I. Osband, C. Blundell, A. Pritzel, and B. Van Roy, "Deep exploration via bootstrapped DQN," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2016, pp. 4026–4034.

[10] L. Espeholt *et al.*, "IMPALA: Scalable distributed deep-RL with importance weighted actor-learner architectures," in *Proc. 35th Int. Conf. Mach. Learn. (ICML)*, 2018, pp. 1407–1416.

[11] M. G. Bellemare, Y. Naddaf, J. Veness, and M. Bowling, "The Arcade Learning Environment: An evaluation platform for general agents," *J. Artif. Intell. Res.*, vol. 47, pp. 253–279, 2013.

[12] M. C. Machado, M. G. Bellemare, E. Talvitie, J. Veness, M. Hausknecht, and M. Bowling, "Revisiting the Arcade Learning Environment: Evaluation protocols and open problems for general agents," *J. Artif. Intell. Res.*, vol. 61, pp. 523–562, 2018.

[13] M. Towers *et al.*, "Gymnasium: A standardized interface for reinforcement learning environments," arXiv:2407.17032, 2024.